

2017「应用微观计量经济学」暑期学校

计量经济学回顾

司继春

上海对外经贸大学

2017年8月

什么是计量经济学?

应用场景分类:

1. 微观计量
2. 宏观计量
3. 金融计量

工具方法分类:

1. 简约式 (reduced form)
2. 结构式 (structural form)

微观计量经济学的任务

Heckman(2008)提出，因果推断的三个任务：

1. 定义问题、假说或者反事实——逻辑、理论与想象
2. 从总体数据中识别参数——如果没有抽样偏差，能否还原反事实？
3. 从实际数据中识别参数——统计理论，估计与检验

「Effect of Causes」 versus 「Causes of Effects」

基本工具：作为拟合的回归

如果有数据 $(y_i, x_i')'$ ，令残差 $e_i = y_i - x_i'b$ ，那么不同形式的回归：

1. 普通线性回归：

$$\min_b \sum_{i=1}^N e_i^2$$

2. 中位数回归：

$$\min_b \sum_{i=1}^N |e_i|$$

3. q-分位数回归：

$$\min_b \sum_{i=1}^N \psi_q(e_i)$$


其中

$$\psi_q(x) = \begin{cases} qx & x > 0 \\ (q-1)x & x \leq 0 \end{cases}$$

4. Probit、Logit回归

分位数回归

$\psi_q(x)$:



最小二乘法 (OLS)

如果我们记:

$$Y = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_N \end{bmatrix}, X = [X_1, X_2, \dots, X_K] = \begin{bmatrix} X_{11} & X_{12} & \cdots & X_{1K} \\ X_{21} & X_{22} & \cdots & X_{2K} \\ \vdots & \vdots & \ddots & \vdots \\ X_{N1} & X_{N2} & \cdots & X_{NK} \end{bmatrix}$$

那么回归方程可以写作:

$$Y = Xb + e$$

而最小二乘法最小化:

$$\min_b (Y - Xb)'(Y - Xb)$$

从而得到: $\hat{b} = (X'X)^{-1} X'Y$ 。

最小二乘法的几何性质

根据OLS，由于 $\hat{b} = (X'X)^{-1} X'Y$ ，因而Y的拟合值为：

$$\hat{Y} = X\hat{b} = X(X'X)^{-1} X'Y$$

记 $P = X(X'X)^{-1} X'$ ，从而 $\hat{Y} = PY$ ，即P做为一个线性变换，将向量Y变换到其拟合值 \hat{Y} 。

而残差为：

$$\hat{e} = Y - \hat{Y} = [I - P] Y$$

记 $M = I - P$ ，从而 $\hat{e} = MY$ ，即线性变换M将向量Y变换到其残差 \hat{e} 。

最小二乘法的几何性质

M和P矩阵具有以下性质：

$$P^2 = X (X'X)^{-1} X'X (X'X)^{-1} X' = X (X'X)^{-1} X' = P$$

$$M^2 = (I - P) (I - P) = I - P - P + P^2 = I - P = M$$

如果矩阵A满足 $A^2 = A$ ，那么我们称A为幂等矩阵（idempotent matrix）。可见P和M矩阵都是对称的幂等矩阵，或者投影矩阵。

最小二乘法的几何性质


注意到：

$$PM = P(I - P) = P - P^2 = 0$$

因而如果计算Y的拟合值 \hat{Y} 与残差 \hat{e} 之间的内积，有：

$$\hat{Y}'\hat{e} = Y'PMY = 0$$

即拟合值 \hat{Y} 与残差 \hat{e} 正交。




最小二乘法的几何性质

由于

$$\hat{Y} = PY = Xb = \sum_{j=1}^k b_j X_j$$

因而 \hat{Y} 是 X_j 的一个线性组合，且由于残差 $\hat{e} = Y - \hat{Y}$ 与 X 平面正交，因而我们称 $\hat{Y} = PY$ 为一个线性投影（linear projection）。

最小二乘法的几何性质



条件期望

以上讨论了向量空间中的投影。条件期望 (conditional expectation) 可以看成是无限维函数空间中的正交投影。
对于随机变量 y 和随机向量 x ，如果我们希望用 x 最优的预测 y ，可以设立如下目标函数：

$$h^*(x) = \arg \min_{h \in \mathbb{H}} \mathbb{E} [y - h(x)]^2$$


其中 h 为任意的函数形式。

我们记以上最优函数 $h^*(x)$ 为 $\mathbb{E}(y|x)$ ，即随机变量 y 给定 x 的条件期望。

条件期望的性质

1. $\mathbb{E}(f(\mathbf{x}) | \mathbf{x}) = f(\mathbf{x})$
2. $\mathbb{E}([y - \mathbb{E}(y|\mathbf{x})] \cdot g(\mathbf{x})) = 0$
3. $\mathbb{E}[\mathbb{E}(y|\mathbf{x}_1, \mathbf{x}_2) | \mathbf{x}_1] = \mathbb{E}(y|\mathbf{x}_1)$
4. $\mathbb{E}(f(\mathbf{x}) y | \mathbf{x}) = f(\mathbf{x}) \mathbb{E}(y|\mathbf{x})$

迭代期望公式



条件期望

下图中代表两个四面骰子的结果，方框中代表两个骰子之和。
记 x_1 为第一个骰子的结果， x_2 为第二个骰子的结果，
而 y 为两个骰子的和。

4	5	6	7	8
3	4	5	6	7
2	3	4	5	6
1	2	3	4	5
	1	2	3	4

那么 $\mathbb{E}(x_1|y=3)=?$

偏效应

在计量经济学中，由于维数问题（dimension problem）以及支撑问题（support problem），我们通常设定一个参数模型，将条件期望定义的函数范围限制在一个参数族内：

$$\beta^* = \arg \min_{\beta \in \mathbb{R}^k} [y - h_{\beta}(x)]^2$$

其中 $h_{\beta}(x)$ 为一个依赖于参数 β 的已知的函数形式。最常用的如线性回归：

$$h_{\beta}(x) = x'\beta$$

1. 与线性回归区别：总体 v.s. 样本
2. 如果令 $y = x'\beta + u$ ，在这里 $\mathbb{E}(u|x) = 0$ 是假设么？

偏效应

在参数模型下，偏效应为：

$$\frac{\partial \mathbb{E}(y|x)}{\partial x_j} = \frac{\partial h_\beta(x)}{\partial x_j}$$

1. 线性模型： $h_\beta(x) = x'\beta$ ，则偏效应为 $\frac{\partial \mathbb{E}(y|x)}{\partial x_j} = \beta_j$
2. $h_\beta(x) = \beta_1 x_1 + \beta_2 x_1^2 + \tilde{x}'\delta$ ，则 x_1 的偏效应为 $\frac{\partial \mathbb{E}(y|x)}{\partial x_1} = \beta_1 + 2\beta_2 x_1$
3. $h_\beta(x) = \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1 x_2 + \tilde{x}'\delta$ ，则 x_1 的偏效应为 $\frac{\partial \mathbb{E}(y|x)}{\partial x_1} = \beta_1 + \beta_3 x_2$
4. $h_\beta(x) = \exp\{\beta_1 x_1 + \beta_2 \ln x_2\}$ ，则 x_2 的偏效应为 $\frac{\partial \mathbb{E}(y|x)}{\partial x_2} = \beta_2 \exp\{\beta_1 x_1 + \beta_2 \ln x_2\} \frac{1}{x_2}$ 。

偏效应

对于Probit/Logit模型:

$$P(y = 1|x) = \mathbb{E}(y = 1|x) = F(x'\beta)$$

则偏效应:

$$\frac{\partial \mathbb{E}(y = 1|x)}{\partial x_j} = \frac{\partial F(x'\beta)}{\partial x_j} = f(x'\beta) \beta_j$$

解释: 当 x 增加一单位所带来的 y 的概率的变化, 随着 x 的改变而改变。

平均偏效应:

$$APE = \mathbb{E}[f(x'\beta) \beta_j]$$

而PEA (partial effects on average) 为:

$$PEA = f[\mathbb{E}(x'\beta)] \beta_j$$

几个独立性假定

1. $Y \perp\!\!\!\perp W \iff F_{W,Y}(w,y) = f_W(w) f_Y(y)$
2. $\mathbb{E}(Y|W) = \mathbb{E}(Y)$
3. $\text{Cov}(Y, W) = 0$
4. $Y \perp\!\!\!\perp W|X \iff F_{W,Y|X}(w,y|x) = f_{W|X}(w|x) f_{Y|X}(y|x)$
5. $\mathbb{E}(Y|W, X) = \mathbb{E}(Y|X)$


条件期望的估计

1. 非参数方法：核密度估计、Sieve估计
 - 1.1 优点：无函数形式假定
 - 1.2 缺点：维数问题、支撑问题
2. 参数方法：假定 $h(x)$ 的函数形式
 - 2.1 优点：无维数问题、支撑问题
 - 2.2 缺点：需要假设函数形式

非参数核密度估计

经验分布函数：

$$\hat{F}(x) = \frac{1}{N} \sum_{i=1}^N 1(x_i \leq x)$$



非参数核密度估计


根据导数定义：

$$f(x) = \lim_{h \rightarrow 0} \frac{F(x+h) - F(x-h)}{2h}$$

如果用经验分布函数替代分布函数，得到：

$$\begin{aligned}\hat{f}(x) &= \frac{\hat{F}(x+h) - \hat{F}(x-h)}{2h} \\ &= \sum_{i=1}^N \frac{1(x-h \leq x_i \leq x+h)}{2Nh} \\ &= \frac{1}{Nh} \sum_{i=1}^N \frac{1}{2} \cdot 1\left(\frac{|x - x_i|}{h} \leq 1\right)\end{aligned}$$

非参数核密度估计



非参数核密度估计

然而以上估计不够光滑，注意到，如果记 $K_0(t) = \frac{1}{2} \cdot 1(t < 1)$ ，那么上述估计可以写为：

$$\hat{f} = \frac{1}{Nh} \sum_{i=1}^N K_0\left(\frac{|x - x_i|}{h}\right)$$

可以替换 $K_0(t)$ 为任意的密度函数，如正态分布密度函数，则：

$$\hat{f} = \frac{1}{Nh} \sum_{i=1}^N K\left(\frac{|x - x_i|}{h}\right)$$

仍然为密度函数。我们称 $K(t)$ 为核函数。

1. 随着 $N \rightarrow \infty$, $h \rightarrow 0$
2. h 的选取: cross-validation/plug-in
3. bias-variance tradeoff

非参数回归

如果设定

$$y = g(x) + u$$

且 $\mathbb{E}(u|x) = 0$ ，那么：

$$\mathbb{E}(y|x) = \int y f(y|x) dy = \frac{\int y f(y, x) dy}{f_X(x)}$$

如果使用对称的核函数估计其中的两个密度函数，则非参数回归可以写为：

$$\frac{\sum_i K\left(\frac{x-x_i}{h}\right) Y_i}{\sum_i K\left(\frac{x-x_i}{h}\right)}$$

或者称核平滑 (kernel smoothing) 。

半参数回归

很多时候我们可以不完全非参数设定模型，而是使用：

$$y = \mathbf{x}'\beta + g(z) + u$$

其中 $\mathbb{E}(u|\mathbf{x}, z) = 0$ 。根据迭代期望公式：

$$\mathbb{E}(y|z) = \mathbb{E}[\mathbb{E}(y|\mathbf{x}, z) | z] = \mathbb{E}(\mathbf{x}|z)'\beta + g(z)$$

以上两式相减：

$$y - \mathbb{E}(y|z) = [\mathbf{x} - \mathbb{E}(\mathbf{x}|z)]'\beta + u$$

1. 分别用 y 和 \mathbf{x} 对 z 做非参数回归得到残差
2. 使用两个残差做线性回归

Simpson悖论

- ▶ 假设人群中两类人，吃素的和吃肉的，记 $d_i = 1$ 为素食主义者， $d_i = 0$ 为肉食者。记 $x_i = 1$ 为女性， $x_i = 0$ 为男性。
- ▶ 假设是否吃素对寿命并没有影响，素食主义者的寿命为：

$$y_{1i} = 70 + 10x_i + u_{1i}$$

而肉食者的寿命为：

$$y_{0i} = 70 + 10x_i + u_{0i}$$

- ▶ 此时，由于 $d_i \perp\!\!\!\perp (y_{0i}, y_{1i})$ ，因而素食主义者与肉食主义者的寿命差别为0：

$$\mathbb{E}(y_{1i}|d_i = 1) - \mathbb{E}(y_{0i}|d_i = 0) = \mathbb{E}(y_{1i}) - \mathbb{E}(y_{0i}) = 0$$

Simpson悖论

- ▶ 现在，假设素食主义者在男女性别中的比例是不一样的，假设女性中素食主义者的比例为75%，男性为20%，即：

$$P(d_i = 1|x_i = 1) = 0.8$$

$$P(d_i = 1|x_i = 0) = 0.1$$

- ▶ 那么：

$$\begin{aligned} P(x_i = 1|d_i = 1) &= \frac{P(d_i = 1|x_i = 1) P(x_i = 1)}{P(d_i = 1|x_i = 1) P(x_i = 1) + P(d_i = 1|x_i = 0) P(x_i = 0)} \\ &= \frac{0.8}{0.8 + 0.1} = \frac{8}{9} \end{aligned}$$

同理：

$$P(x_i = 1|d_i = 0) = \frac{0.2}{0.2 + 0.9} = \frac{2}{11}$$

Simpson悖论

- ▶ 此时，素食主义者的寿命：

$$\begin{aligned}\mathbb{E}(y_{1i}|d_i = 1) &= \mathbb{E}(y_{1i}|d_i = 1, x_i = 1) P(x_i = 1|d_i = 1) \\ &\quad + \mathbb{E}(y_{0i}|d_i = 1, x_i = 0) P(x_i = 0|d_i = 1) \\ &= 80 \times \frac{8}{9} + 70 \times \frac{1}{9} = 78.9\end{aligned}$$

- ▶ 而同理，

$$\begin{aligned}\mathbb{E}(y_{0i}|d_i = 0) &= \mathbb{E}(y_{0i}|d_i = 0, x_i = 1) P(x_i = 1|d_i = 0) \\ &\quad + \mathbb{E}(y_{0i}|d_i = 0, x_i = 0) P(x_i = 0|d_i = 0) \\ &= 80 \times \frac{2}{11} + 70 \times \frac{9}{11} = 71.8\end{aligned}$$

- ▶ 由于 $d_i \perp\!\!\!\perp (y_{0i}, y_{1i})$ 不成立 (Why?)，因而看起来素食主义者更长寿。

Simpson悖论

- ▶ 然而此时，如果在相同性别组内进行比较，则可以得到素食无影响的结论：

$$\mathbb{E}(y_i | x_i = 1, d_i = 1) - \mathbb{E}(y_i | x_i = 1, d_i = 0) = 0$$

$$\mathbb{E}(y_i | x_i = 0, d_i = 1) - \mathbb{E}(y_i | x_i = 0, d_i = 0) = 0$$

- ▶ 在这里，尽管 $d_i \perp\!\!\!\perp (y_{0i}, y_{1i})$ 不成立，但是 $d_i \perp\!\!\!\perp (y_{0i}, y_{1i}) | x_i$ 成立。

Simpson悖论

如果 $d_i \perp\!\!\!\perp (y_{0i}, y_{1i}) | x_i$ 也不成立呢?

- ▶ 令 $d_i = 1 (x_i - u_{1i} + u_{0i} \geq 0)$ 。
- ▶ 在此设定下，即使给定 x_i ， d_i 仍然与不可观测的 u_{1i}, u_{0i} 相关，而 u_{1i}, u_{0i} 则直接影响了 y_{1i}, y_{0i} 。
- ▶ 注意，如果 $-u_{1i} + u_{0i}$ 比较高，则成为素食者的概率会提高，即如果一个人吃素食的寿命更高，反而选择素食的概率更低，那么：

$$\begin{aligned} \mathbb{E}(y_i | x_i = 1, d_i = 1) - \mathbb{E}(y_i | x_i = 1, d_i = 0) \\ = \mathbb{E}(80 + u_{1i} | d_i = 1) - \mathbb{E}(80 + u_{0i} | d_i = 0) \\ = \mathbb{E}(u_{1i} | d_i = 1) - \mathbb{E}(u_{0i} | d_i = 0) \end{aligned}$$

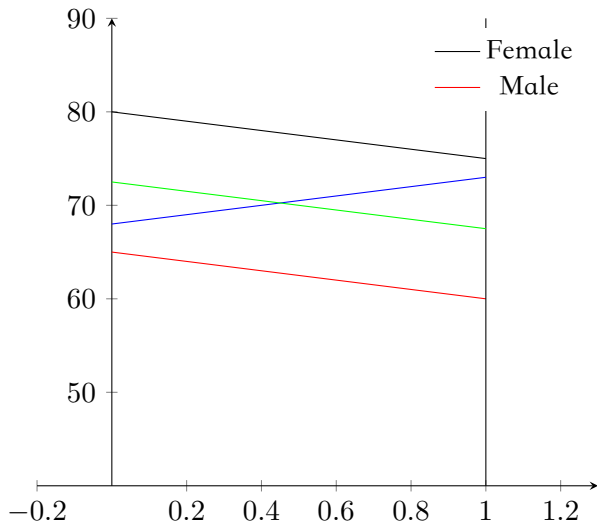
Simpson悖论

最终 $\mathbb{E}(y_i | d_i = 1) - \mathbb{E}(y_i | d_i = 0)$ 符号取决于两种偏差:

$$\begin{aligned}\mathbb{E}(y | d = 1) - \mathbb{E}(y | d = 0) = & \mathbb{E}(y | x = 1, d = 1) P(x = 1 | d = 1) \\ & + \mathbb{E}(y | x = 0, d = 1) P(x = 0 | d = 1) \\ & - \mathbb{E}(y | x = 1, d = 0) P(x = 1 | d = 0) \\ & - \mathbb{E}(y | x = 0, d = 0) P(x = 0 | d = 0)\end{aligned}$$

1. 由于 $d_i \perp\!\!\!\perp (y_{0i}, y_{1i}) | x_i$ 不成立, 因而 $\mathbb{E}(y | x, d) \neq \mathbb{E}(y | x)$
2. $P(x = 1 | d = 1), P(x = 1 | d = 0)$, 两个比例不相等。

Simpson悖论



线性回归

对于模型

$$y_i = \mathbf{x}_i' \beta + u_i$$

如果假设：

$$\mathbb{E}(u_i | \mathbf{x}_i) = 0$$

如何估计参数 β ?

线性回归

通常得到最小二乘的两个途径：

1. 最小二乘法

- ▶ 强调拟合而并没有使用 $\mathbb{E}(u_i|x_i) = 0$ 这一假设。

2. (拟) 极大似然估计

- ▶ 使用了比 $\mathbb{E}(u_i|x_i) = 0$ 更强的假设，即 $f(u_i|x_i)$ 的分布假设

第三个更常用的办法：矩估计。

线性回归

矩估计的步骤:

1. 根据模型得到一些总体矩的推论，并检查识别条件
 - ▶ $\mathbb{E}(u_i|x_i) = 0 \Rightarrow \mathbb{E}(x_i u_i) = \mathbb{E}[\mathbb{E}(x_i u_i|x_i)] = \mathbb{E}[x_i \mathbb{E}(u_i|x_i)] = 0。$
 - ▶ 从而: $\mathbb{E}[x_i (y_i - x_i' \beta)] = 0$
2. 将总体矩用样本矩进行替代 (\sum 替代 \mathbb{E})，并将参数写成待估计形式
 - ▶ $\sum_i [x_i (y_i - x_i' \hat{\beta})] = 0$
3. 解以上方程 (组) 得到估计
 - ▶ $\sum_i [x_i (y_i - x_i' \hat{\beta})] = \sum_i x_i y_i - \sum_i x_i x_i' \hat{\beta} = 0$
 - ▶ $\hat{\beta} = (\sum_i x_i x_i')^{-1} \sum x_i y_i$

线性回归

回归的本质：比较

- ▶ 如果令 $x_i = 0/1$ ，那么我们的矩条件为：

$$\mathbb{E}[x_i (y_i - \alpha - \beta x_i)] = 0$$

$$\mathbb{E}[y_i - \alpha - \beta x_i] = 0$$

解得：

$$\beta = \mathbb{E}(y_i | x_i = 1) - \mathbb{E}(y_i | x_i = 0)$$

- ▶ 使用样本矩替代，即：

$$\hat{\beta} = \bar{y}_1 - \bar{y}_0$$

线性回归

分步回归：variation究竟来自哪里？

- ▶ 对于线性回归模型： $y_i = x_i'\beta + z_i'\delta + u_i$
- ▶ β 的OLS估计与以下步骤得到的回归系数是等价的：
 1. 分别用 x 和 y 对 z 做回归得到残差 e_x, e_y
 2. 用 e_y 对 e_x 做回归，得到 β 的估计。

启示：

1. 只有 z 对 x 和 y 不能解释的那部分才是可用的variation
2. 为了得到 β 的一致估计，只需要 $u \perp x|z$ 。

线性回归

如果 $y_i = x_i'\beta + z_i'\delta + u_i$ ，其中 $z_i = 0/1$ 。按照分步回归的步骤：

1. 用 x 和 y 对 z 做回归，得到残差。注意由于 z 为0-1变量，因而实际结果是 x 和 y 被分组去均值。
2. 用 e_y 对 e_x 做回归，得到 β 的估计。

注意在以上步骤中，实际使用的variation是被去掉组均值的残差，因而不同组别之间没有variation，是一个「组内」估计量。

线性回归

异方差的处理:

- ▶ 从参数估计的角度讲, 没有必要对异方差做特殊处理, OLS 的估计是一致的, 尽管不再是有效的。
- ▶ 从假设检验的角度讲, 不能忽略异方差的影响, 异方差导致参数估计的s.e.不正确

解决方法: White异方差:

$$\text{Var}(\hat{\beta}) = [X'X]^{-1} \left[\sum_{i=1}^N \hat{u}_i^2 x_i x_i' \right] [X'X]^{-1}$$

线性回归

很多时候我们使用的是分组数据：

$$y_{ig} = x'_{ig}\beta + u_{ig}$$

在组内，很多时候 u_{ig} 之间是相关的：

$$\mathbb{E}(u_{ig}u_{jg'}) = \begin{cases} \sigma_{(ij)g} & g = g' \\ 0 & g \neq g' \end{cases}$$

此时，仅仅做异方差文件的s.e.是不够的。

线性回归

可能的原因：组内某些不能观察到的变量对 y_{ig} 有影响。

- ▶ 例如，如果 y_{ig} 是班级内学生的成绩，那么 g 是班级，教师质量等都可能影响成绩。

很多时候不能单纯使用group dummy来解决

- ▶ 例如，学生努力程度的peer effect

线性回归

使用：

$$\text{Var}(\hat{\beta}) = [\mathbf{X}'\mathbf{X}]^{-1} \left[\sum_g \mathbf{x}'_g \hat{u}_g \hat{u}'_g \mathbf{x}_g \right] [\mathbf{X}'\mathbf{X}]^{-1}$$

$$\begin{bmatrix} \sigma^2_{(11)1} & \cdots & \sigma_{(1N_1)1} & 0 & \cdots & 0 & \cdots & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots & & \vdots & & \vdots \\ \sigma^2_{(N_11)1} & & \sigma_{(N_1N_1)1} & 0 & & 0 & & 0 & & 0 \\ 0 & \cdots & 0 & \sigma^2_{(11)2} & \cdots & \sigma_{(1N_2)2} & & \vdots & & \vdots \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots & & \vdots & & \vdots \\ 0 & \cdots & 0 & \sigma_{(N_21)2} & \cdots & \sigma^2_{(N_2N_2)2} & & \vdots & & \vdots \\ & & & & & & \ddots & \vdots & & \vdots \\ & & & & & & & \sigma^2_{(11)g} & \cdots & \sigma_{(1N_g)g} \\ & & & & & & & \vdots & \ddots & \vdots \\ & & & & & & & \sigma_{(N_g1)g} & \cdots & \sigma^2_{(N_gN_g)g} \end{bmatrix}$$

线性回归

不止一组的情况：

- ▶ 如果是嵌套的，比如学校、班级，应该cluster在更高的一级
- ▶ 如果不是嵌套的：
 - ▶ 控制一组的固定效应，cluster另外一组
 - ▶ two-way cluster, Cameron, Gelbach and Miller, 2006
- ▶ 现实中：
 - ▶ `reg`中的`cluster()`只能cluster一组
 - ▶ `reghdfe`

线性回归

一般来说，cluster的标准误更大，因而参数的置信区间更大，更容易不显著。cluster标准误比i.i.d的标准误扩大了：

$$\sqrt{1 + \rho_x \rho_u (\bar{N} - 1)}$$

其中 ρ_x 为解释变量的组内相关性， ρ_u 为误差项组内相关性，而 \bar{N} 为平均的组大小。

内生性问题

在线性回归中，我们假设了 $\mathbb{E}(u|x) = 0$ ，从而得到了最小二乘估计。当这一假定被违背时，我们称为有内生性问题。

1. 微观、宏观中的「内生变量」与计量中的内生性的联系区别？
2. 内生性可能的原因：
 - ▶ 互为因果
 - ▶ 遗漏变量
 - ▶ 度量误差
 - ▶ 自选择
 - ▶

工具变量

解决方案：找到外生的影响 x 但是不会影响 y 的变量，即工具变量 z 。

如果我们要估计的方程为：

$$y = \alpha + \beta y_1 + u$$

然而 $\text{Cov}(x, u) \neq 0$ ，但是我们可以找到一个 z ，使得 $\text{Cov}(z, u) = 0$ ，且：

$$y_1 = \gamma + \delta z + e$$

我们把以上方程带入结构式，得到：

$$\begin{aligned} y &= \alpha + \beta(\gamma + \delta z + e) + u \\ &= (\alpha + \beta\gamma) + \beta\delta z + u + \beta e \end{aligned}$$

我们称上式为简约式。

工具变量

现在两个式子：

$$x = \gamma + \delta z + e$$

以及

$$\begin{aligned} y &= (\alpha + \beta\gamma) + \beta\delta z + u + \beta e \\ &= \gamma^* + \delta^* z + v \end{aligned}$$

都不存在内生性问题，因而我们可以一致估计 $\gamma, \delta, \gamma^*, \delta^*$ 。进而，可以得到 β ：

$$\beta = \frac{\delta^*}{\delta} = \frac{\beta\delta}{\delta}$$

假设：

1. z 与 u 不相关
2. 分母（ δ ）不为0。

工具变量

一般情况下，如果估计方程：

$$y = \alpha y_1 + x'\beta + u$$

其中 y_1 为关心的内生变量，即 $\text{Cov}(y_1, u) \neq 0$ ，但是存在工具变量 z ，使得 $\mathbb{E}(u|z) = 0$ ，且 $\mathbb{E}(y_1|x, z) \neq \mathbb{E}(y_1|x)$ ，那么 y_1 的简约式可以写为：

$$y_1 = z'\gamma + x'\delta + v$$

那么可以通过工具变量达到对 α 的识别。

工具变量

工具变量的理解：以联立方程为例

如果存在互为因果的两个内生变量 y_1, y_2 ，满足：

$$y_1 = \alpha_1 y_2 + x_1 \beta_1 + u_1$$

$$y_2 = \alpha_2 y_1 + x_2 \beta_2 + u_2$$

联立两个方程，可以得到：

$$\begin{aligned} y_2 &= \alpha_2 (\alpha_1 y_2 + x_1 \beta_1 + u_1) + x_2 \beta_2 + u_2 \\ &= \alpha_1 \alpha_2 y_2 + \alpha_2 x_1 \beta_1 + x_2 \beta_2 + \alpha_2 u_1 + u_2 \\ &= \frac{\alpha_2}{1 - \alpha_1 \alpha_2} x_1 \beta_1 + \frac{1}{1 - \alpha_1 \alpha_2} x_2 \beta_2 + \frac{\alpha_2 u_1 + u_2}{1 - \alpha_1 \alpha_2} \\ &\triangleq x' \delta + v \end{aligned}$$

使用决定 y_2 、但同时不决定 y_1 的外生的扰动，即包含在 x_2 而不包含在 x_1 的变量(z)进行识别。

工具变量

估计：两阶段最小二乘法 (2SLS)

1. 第一阶段回归，对 y_1 的简约式进行回归：

$$y_1 = z'\gamma + x'\delta + v$$

$$\hat{y}_1 = z'\hat{\gamma} + x'\hat{\delta}$$

或者 $\hat{Y}_1 = P_Z Y_1$ ，其中 $Z = (Z, X)$ ， $P_Z = Z(Z'Z)^{-1}Z'$ 。

2. 第二阶段回归，用 \hat{y}_1 代替 y_1 ：

$$y = \hat{\alpha}\hat{y}_1 + x'\hat{\beta} + \hat{e}$$

或者： $(\hat{\alpha}', \hat{\beta}')' = (XP_Z Z)^{-1} (XP_Z Y)$ ，其中 $X = (Y_1, X)$ 。

注意：不要手动算两阶段最小二乘，差别：在算标准误的时候用 \hat{e} 还是 $\hat{u} = y - \hat{\alpha}y_1 + x'\hat{\beta}$ ？

工具变量

工具变量的理解：我们使用了那些variation?

1. 第一阶段回归：

$$\hat{y}_1 = z'\hat{\gamma} + x'\hat{\delta}$$

2. 第二阶段回归：

$$y = \alpha\hat{y}_1 + x'\hat{\beta} + \hat{e}$$

考虑使用分步回归，即先用 \hat{y}_1 对 x 做回归得到残差，等价于用 $z'\hat{\gamma}$ 对 x 做回归，得到残差，再用 y 对以上残差做回归。
只使用了单纯因为工具变量而导致的 y_1 的变化的部分variation。
因而需要考虑清楚工具变量如何影响内生变量。
例：用电供给，用天气做IV或者用大宗商品价格做IV?

广义矩估计 (Generalized Method of Moments) 提供了一个简单实用的估计、检验框架。

- ▶ 依赖于矩条件 (Moment Condition)
- ▶ 几乎所有的经典计量方法都可以看成是GMM的特例，如 OLS、2SLS等
- ▶ 特别的，绝大多数情况下，MLE也可以看成是GMM的特例

考虑一个简单的求正态分布参数的问题。如果 $x_i \sim N(\mu, \sigma^2)$ ，为了估计 μ, σ^2 ，我们可以：

1. MLE: 最大化

$$\sum_i \left[-\frac{1}{2} \ln(2\pi) - \ln \sigma - \frac{(x_i - \mu)^2}{2\sigma^2} \right]$$

2. 矩估计 (Method of Moments) : 由

于 $\mathbb{E}(x_i) = \mu$, $\mathbb{E}(x_i^2) = \sigma^2 + \mu^2$, 那么解方程:

$$\begin{cases} \frac{1}{N} \sum_i (x_i - \hat{\mu}) & = 0 \\ \frac{1}{N} \sum_i (x_i^2 - \hat{\mu}^2 - \hat{\sigma}^2) & = 0 \end{cases}$$

然而我们知道，对于正态分布而言，不仅仅存在一阶矩、二阶矩，还有三阶矩、四阶矩以及更高阶矩，比如 $\mathbb{E}(x_i^3) = \mu^3 + 3\mu\sigma^2$ ，如果联立：

$$\begin{cases} \frac{1}{N} \sum_i (x_i - \hat{\mu}) & = 0 \\ \frac{1}{N} \sum_i (x_i^2 - \hat{\mu}^2 - \hat{\sigma}^2) & = 0 \\ \frac{1}{N} \sum_i (x_i^3 - \hat{\mu}^3 - 3\hat{\mu}\hat{\sigma}^2) & = 0 \end{cases}$$

两个未知数、三个方程，无解。

其他矩估计：

1. 线性回归，矩条件： $\mathbb{E}(x_i u_i) = 0$ ，从而矩估计为：

$$\frac{1}{N} \sum_i x_i u_i = \frac{1}{N} \sum_i x_i (y_i - x_i' \hat{\beta}) = 0$$

由于 x_i 为 k 维向量，待估参数 β 也是 k 维向量，从而可以解出估计参数。

2. 工具变量，如果记 $z^* = (z', x')'$ ，即所有外生变量，那么矩条件： $\mathbb{E}(z_i^* u_i) = 0$ ，矩估计为：

$$\frac{1}{N} \sum_i z_i^* (y_i - \alpha y_{1i} - x_i' \hat{\beta}) = 0$$

如果工具变量（包含 x ）个数 L 等于待估系数个数（ x 的维数加上内生变量个数） K ，那么仍然有解。

3. 如果 $L > K$ ，无解。

前两种情况：恰好识别；第三种情况：过度识别
(overidentification)

GMM

在一定范围内，工具变量（矩条件）越多，提供的variation也越多，所以我们希望尽可能的用比较多的工具变量（矩条件）。如果有总体矩条件

$$\mathbb{E}[m(w_i, \theta)] = 0$$

其中 $m(\cdot)$ 为 $L \times 1$ 维，即有 L 个矩条件， θ 为 K 维，即有 K 个待估计参数。

1. 想法1：最小化

$$\min_{\theta} \sum_i m(w_i, \theta)' m(w_i, \theta) = \sum_i \left[\sum_{l=1}^L m_l(w_i, \theta)^2 \right]$$

2. 想法2：继续推广，最小化：

$$\min_{\theta} \left[\sum_i m(w_i, \theta) \right]' W \left[\sum_i m(w_i, \theta) \right]$$

其中 W 为 $L \times L$ 的正定的权重矩阵。

- ▶ 给定任意的 θ ，目标函数总是 ≥ 0 。
- ▶ 给定任意的正定矩阵 W ，当且仅当每个矩 $\sum_i m_i(w_i, \theta)$ 都等于0时，目标函数等于0。
- ▶ 因而以上目标函数保证每个矩条件都充分贴近与0，
- ▶ 识别条件：存在唯一解使得

$$\mathbb{E}[m(w_i, \theta)] = 0$$

如果给定任意一个权重矩阵 W ，都可以得到不同的估计结果：

- ▶ 理论上，给定任意的正定权重矩阵 W ，都可以得到一致的结果
- ▶ 然而任意的正定权重矩阵所得到的估计结果渐进方差不相同
- ▶ 存在一个最优权重矩阵 W^* 使得估计结果方差最小：

$$W^* = \left(\mathbb{E} \left[m(w_i, \theta) m(w_i, \theta)' \right] \right)^{-1}$$

- ▶ 可以使用：

$$\hat{W} = \left(\sum_{i=1}^N \left[m(w_i, \theta) m(w_i, \theta)' \right] \right)^{-1}$$

实际操作中：

1. 使用任意的正定矩阵（如单位阵）作为权重矩阵进行估计，得到第一次估计 $\hat{\theta}_0$
2. 将 $\hat{\theta}_0$ 带入

$$\hat{W}_1 = \left(\sum_{i=1}^N [m(w_i, \theta) m(w_i, \theta)'] \right)^{-1}$$

得到权重矩阵，再次进行估计（two-step）

3. 或者，重复以上步骤直至收敛。

► Stata: gmm命令； Matlab: GMM工具箱

过度识别检验:

- ▶ 在 $L > K$ 的情形下, 我们可以检验矩条件(工具变量)是否有效。
- ▶ 可以证明, 当使用最优权重矩阵时, GMM目标函数渐进服从 χ^2 分布, 自由度为 $L - K$:

$$\left[\sum_i m(w_i, \hat{\theta}) \right]' \left(\sum_{i=1}^N \left[m(w_i, \hat{\theta}) m(w_i, \hat{\theta})' \right] \right)^{-1} \left[\sum_i m(w_i, \hat{\theta}) \right] \underset{a}{\sim} \chi^2(L - K)$$

- ▶ Hansen's J-statistics

例子：

1. 工具变量，矩条件为： $\mathbb{E}(z_i u_i) = 0$ ，则GMM目标函数：

$$\min \left[\sum_i z_i (y_i - \tilde{x}_i' \tilde{\beta}) \right]' W \left[\sum_i z_i (y_i - \tilde{x}_i' \tilde{\beta}) \right]$$

如果取 $W = Z'Z$ ，则得到了两阶段最小二乘（2SLS）。

2. 在同方差假定下，以上的权重矩阵为最优权重矩阵。
3. 当同方差假定不满足时，以上的权重矩阵不是最优权重矩阵。

例子：动态面板模型：

$$y_{it} = \alpha y_{i,t-1} + \mathbf{x}_{it}'\beta + \eta_i + u_{it}$$

为了消除固定效应：

$$\Delta y_{it} = \alpha \Delta y_{i,t-1} + \Delta \mathbf{x}_{it}'\beta + \Delta u_{it}$$

然而， $\mathbb{E}(\Delta y_{i,t-1} \cdot \Delta u_{it}) = \mathbb{E}(y_{i,t-1} - y_{i,t-2})(u_{it} - u_{i,t-1}) \neq 0$

工具变量： $y_{i,t-3}, y_{i,t-4}, \dots, x_{i,t-1}, \dots$

工具变量

控制函数法：如果估计方程：

$$y = \alpha y_1 + x'\beta + u$$

以及 y_1 的简约式：

$$y_1 = z'\gamma + x'\delta + v$$

在简约式中， y_1 被分解为两部分：

1. $z'\gamma + x'\delta$ 是与 u 不相关的部分
2. 如果 y_1 与 u 相关，则相关性必在 v 里面。

工具变量

因而，如果假定：

$$u = \rho v + e$$

那么待估计方程变为：

$$y = \alpha y_1 + x' \beta + \rho v + e$$

因而如果观察到 v ，就可以直接控制「内生性」 v 从而达到识别。

工具变量

估计步骤:

1. 估计简约式 $y_1 = z'\gamma + x'\delta + v$ 得到 \hat{v}
2. 将 \hat{v} 带入主方程, 使用回归:

$$y = \alpha y_1 + x'\beta + \rho \hat{v} + e$$

进行估计。

检验内生性: $H_0 : \rho = 0$ 。

工具变量

- ▶ 在线性模型下，控制函数法与2SLS等价
- ▶ 控制函数法在很多非线性模型下仍然可以使用，而2SLS不可以。
 - ▶ Probit模型：

$$d_i = 1 (\alpha y_{1i} + \mathbf{x}_i' \beta + u_i \geq 0)$$

$$y_{1i} = \mathbf{z}' \gamma + \mathbf{x}' \delta + v$$

- ▶ 首先估计简约式方程，得到 \hat{v} ，进而回归：

$$d_i = 1 (\alpha y_{1i} + \mathbf{x}_i' \beta + \hat{v}_i + e_i \geq 0)$$

工具变量

- ▶ 或者，可以使用极大似然估计，即假设 (e_i, v_i) 的联合（正态）分布，进而：

$$f(y_i, y_{1i} | x_i, z_i) = f(y_i | y_{1i}, x_i, z_i, v_i) \cdot f(v_i | x_i, z_i)$$

如果假定 (e_i, v_i) 为联合正态分布，即得到有限信息极大似然估计（LIML）。

- ▶ 其他估计方法：k-class估计量

工具变量

工具变量的两个假定：

1. 与误差项不相关——Hansen's J test
2. 与内生变量高度相关

如果第二项假定不满足？

工具变量

以上得知，对于要估计的方程：

$$y = \alpha + \beta y_1 + u$$

以及第一阶段：

$$y_1 = \gamma + \delta z + e$$

估计可以写为：

$$\hat{\beta}_{2SLS} = \frac{\text{Cov}(y, z)}{\text{Cov}(y_1, z)}$$

如果分母趋向于0，IV估计的结果会非常不稳定——弱工具。

工具变量

- ▶ Angrist and Krueger (1991)研究教育回报时，使用了出生季节与州、年份的乘积作为上学时间的工具变量
- ▶ Bound, Jaeger and Baker (1996)对此研究做出了批评，发现随机生成一组出生季节仍然能得到相似的结论。
- ▶ 工具变量太多导致估计结果偏向OLS的估计结果

工具变量

- ▶ 对于少量弱工具：
 - ▶ 诊断弱工具
 - ▶ 使用LIML，并调整置信区间。
- ▶ 对于Many instruments：
 - ▶ 2SLS表现非常差
 - ▶ 使用LIML，或者REQML(Chamberlain and Imbense, 2004)

工具变量

弱工具诊断:

- ▶ 第一阶段 F -value, 一般在一个内生变量一个工具变量的情况下, 大于10
- ▶ Cragg-Donald 统计量 (F -value推广, 当只有一个内生变量时就是 F -value)
- ▶ Stock and Yogo (2005)提出了针对Cragg-Donald 统计量的临界值

置信区间调整:

- ▶ Anderson and Rubin (1949)

工具变量

```
Underidentification test (Anderson canon. corr. LM statistic):           0.124
                                                                    Chi-sq(1) P-val =    0.7249
-----
Weak identification test (Cragg-Donald Wald F statistic):                0.122
Stock-Yogo weak ID test critical values: 10% maximal IV size           16.38
                                         15% maximal IV size           8.96
                                         20% maximal IV size           6.66
                                         25% maximal IV size           5.53
Source: Stock-Yogo (2005).  Reproduced by permission.
-----
Sargan statistic (overidentification test of all instruments):           0.000
                                                                    (equation exactly identified)
```